# TP2 Exploitation de données

# Elasticsearch Query

- \* Toute requête se fait sur l'API REST, elle doit contenir :
- le nom de l'index
- le nom du type

\* Avec curl

- Un opérateur de recherche : count, search
- un identifiant -> Optionnel
- un identifiant -> Optionne
  - curl -XGET 'http://localhost:9200/tests/test/1'
- => Index 'tests', de type 'test', pour le premier document (\_id=1) curl -XGET 'http://localhost:9200/tests/test/ count'
- => Compte le nombre de documents de 'tests/test'
- \*Ou aussi avec Kibana DevTools (http://localhost:5601/app/dev\_tools), ou Cerebro (http://localhost:9000)
- => Voir si besoin TP1

# Requêtes Simples

Le service **search** permet de faire des requêtes simples, On peut écrire la requête avec trois formats (si possible) :

```
    Avec la méthode HTTP GET (web brower), avec le paramètre q=
http://localhost:9200/movies/_search?q=fields.title:foo+bar
```

curl -XGET 'http://localhost:9200/tests/test/ search?q=alien&pretty=true'

• Avec la méthode HTTP POST, avec le paramètre de document JSON « query.json »,pour certaines requêtes complexes en utilisant le DSL (Domain Specific Language), il faut envoyer un document JSON "requête":

```
curl -XPOST « localhost:9200/movies/movie/_search&pretty » -H"Content-Type: application/json » -d @query.json -o output.json => consulter ensuite ce document JSON dans un navigateur Web.
```

Ou via un admin tool (cerebro ou Kibana devtools)

```
GET /movies/_search
{"query":{
"match":{"fields.title":"foo bar"}}
}
```

#### Requêtes Simples

Le service search permet de faire des requêtes simples

- Recherche de mots dans l'ensemble de chaque document
   curl -XGET 'http://localhost:9200/tests/test/\_search?q=alien&pretty=true'
- Dans le titre de chaque document
   curl -XGET 'http://localhost:9200/tests/test/\_search?q=title:alien&pretty=true'
- Combinaison de critères avec l'espace (%20 pour une URL). Ici, la négation est utilisée ("-") curl -XGET 'http://localhost:9200/tests/test/\_search?q=title:alien%20-year:1992&pretty=true'

# Requêtes Simples: Matching

```
Pour avoir une requête complexe en utilisant le DSL (Domain Specific Language), il faut envoyer un document JSon "requête":
curl -XGET http://localhost:9200/tests/test/_search?pretty -d '
{
"query" : ...
```

- Requêtes de simple correspondance (matching)

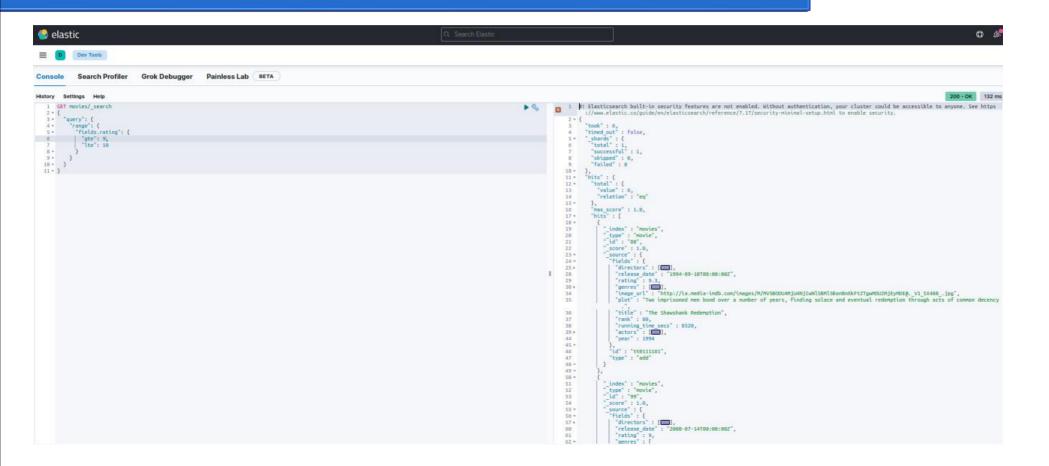
```
{
   "query" : {
    "match" : { "nom_de_l'attribut" : "la\_valeur\_a\_chercher"}
  }
}
```

#### Requêtes Simples: range

- Requêtes d'intervalles (range)

```
{
    "query" : {
        "range" : { "nom_de_l'attribut" : "la\_borne"}
    }
}
```

#### Requêtes Simples: range



- Notions de critère optionnel 'should' (avec calcul de score de pertinence) et d'obligatoire 'must' (sans score). Il faut utiliser le critère en imbriquant dans un opérateur 'bool'

Occur	Description
must	The clause (query) must appear in matching documents and will contribute to the score.
filter	The clause (query) must appear in matching documents. However unlike <code>must</code> the score of the query will be ignored. Filter clauses are executed in filter context, meaning that scoring is ignored and clauses are considered for caching.
should	The clause (query) should appear in the matching document.
must_not	The clause (query) must not appear in the matching documents. Clauses are executed in filter context meaning that scoring is ignored and clauses are considered for caching. Because scoring is ignored, a score of $\emptyset$ for all documents is returned.

The bool query takes a more-matches-is-better approach, so the score from each matching must or

La REF est ici:

should clause will be added together to provide the final score for each document.

<sup>\*</sup> https://www.elastic.co/guide/en/elasticsearch/reference/current/query-dsl.html

<sup>\*</sup> https://www.elastic.co/guide/en/elasticsearch/reference/7.17/query-dsl-bool-query.html

```
#! Elasticsearch built-in security features are not enabled. Without authentication, your cluster could be accessible to anyone. See https:
   ://www.elastic.co/guide/en/elasticsearch/reference/7.17/security-minimal-setup.html to enable security.
    "took" : 0,
    "timed out" : false,
* "shards" : {
      "total" : 1,
      "successful" : 1.
      "skipped" : 0,
      "failed" : 8
. },
hits':{
     "total" : {
        "value" : 2009.
        "relation" : "eq"
      "max score" : 2.0.
      "hits" : [
          "index": "movies",
          "_type" : "movie",
"id" : "114",
          "score" : 2.0,
           source" : {
            "fields" : {
              "directors" : [
                "Quentin Tarantino"
              "release date" : "1994-05-12700:00:00Z",
              "rating" : 9,
               "genres" : [
                "Crime".
                "Drama".
                "Thriller"
               "image url": "http://ia.media-imdb.com/images/M/MVSBMiE800k2NiczOVSBMl5BanBnXkFtZTYwNDQ8NDq4, V1 SX48B .ipg".
               "plot": "The lives of two mob hit men, a boxer, a gangster's wife, and a pair of diner bandits intertwine in four tales of
                violence and redemption.",
              "title" : "Pulp Fiction",
               "rank" : 114,
               "running time secs" : 9240,
               "actors" : [
                "John Travolta",
                "Une Thurman".
                "Samuel L. Jackson"
              "year" : 1994
            "id" : "tt0110912".
            "type" 1 "add"
```

```
POST search
 "query": {
   "bool" : {
     "must" : {
       "term" : { "user.id" : "kimchy" }
     "filter": {
       "term" : { "tags" : "production" }
     "must not" : {
       "range" : {
         "age" : { "gte" : 10, "lte" : 20 }
     "should" : [
       { "term" : { "tags" : "env1" } },
       { "term" : { "tags" : "deployed" } }
     "minimum_should_match" : 1,
     "boost" : 1.0
```

# Requêtes Simples: filter

- Une requête avec l'opérateur 'filter' ne calcule aucun score pour la requête correspondante (même avec 'should')

```
{
    "query": {
        "query": {
            "match": {"nom_de_l'attribut" : "valeur"}
        },
        "filter": {
            "range": {"nom_de_l'attribut" : "valeur"}
    }}}}
```

#### La REF est ici:

- \* https://www.elastic.co/guide/en/elasticsearch/reference/current/query-dsl.html
- \* https://www.elastic.co/guide/en/elasticsearch/reference/7.17/query-dsl-bool-query.html

#### Requêtes Simples: filter

- The title field contains the word search.
- The content field contains the word elasticsearch.
- The status field contains the exact word published.
- The publish date field contains a date from 1 Jan 2015 onwards.

- The query parameter indicates query context.
- The bool and two match clauses are used in query context, which means that they are used to score how well each document matches.
- The filter parameter indicates filter context. Its term and range clauses are used in filter context. They will filter out documents which do not match, but they will not affect the score for matching documents.

https://www.elastic.co/guide/en/elasticsearch/reference/7.17/query-filter-context.html

#### Requetes Simples

Vous êtes mnt prêt pour le TP2 => voir Notebook